Systemy operacyjne

Wykład 11: Systemy plików

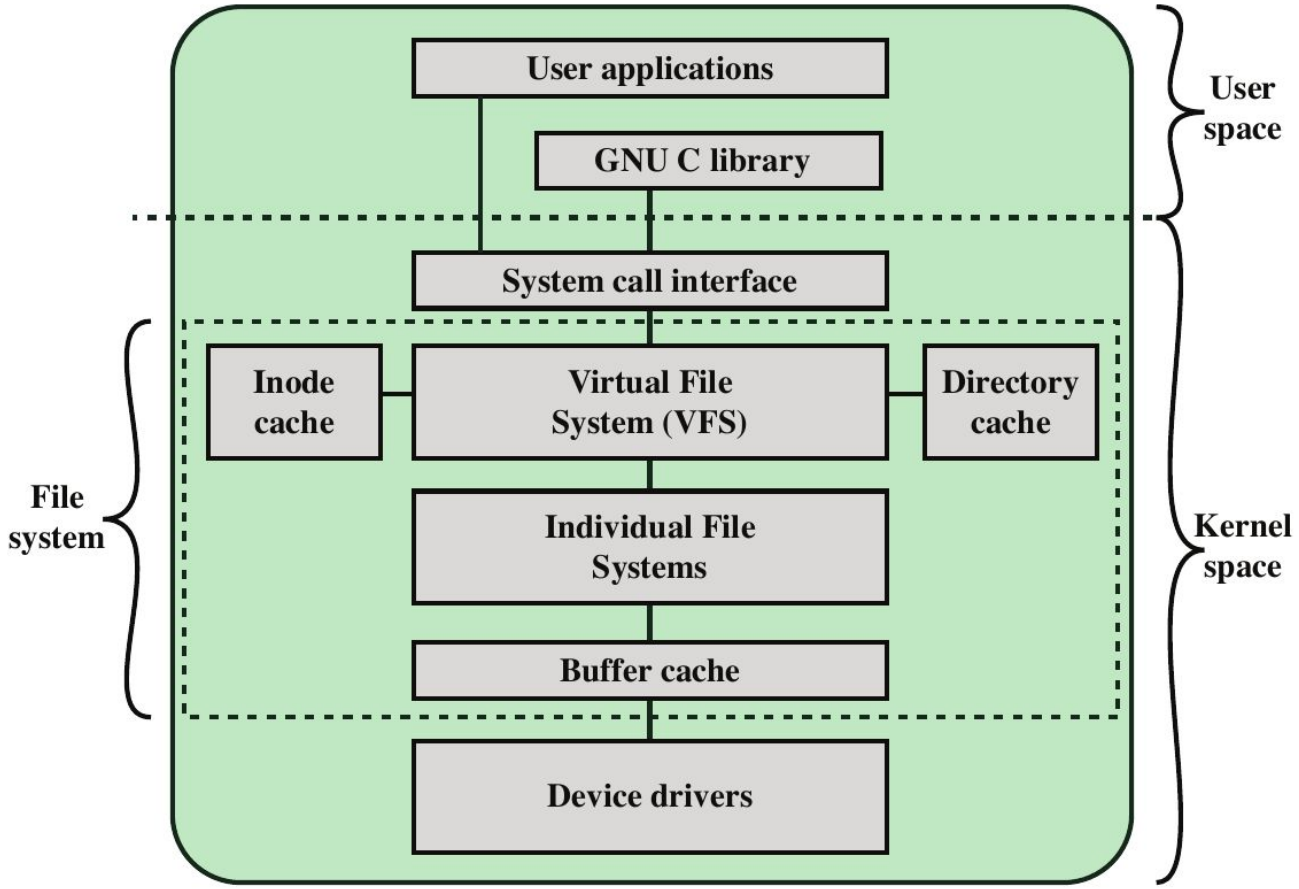

Dziś będziemy mówić o tym jak implementacja wywołań systemowych korzysta z VFS i indywidualnych systemów plików, oraz o organizacji danych na dysku.

The Linux Storage Stack Diagram

Po co nam systemy plików?

1. Przechowywanie danych:
   a. ogólnego przeznaczenia → NTFS, ext4
   b. dyski półprzewodnikowe → JFFS2, APFS
   c. dyski optyczne RO → UDF, ISO 9660
   d. serwerowe → btrfs, ZFS, XFS
   e. rozproszone → NFS, lustrefs
   f. pamięć ulotna → tmpfs (ram dysk)
   g. pamięć ROM → initramfs, squashfs
2. Reprezentacja zasobów jądra:
   a. procesy → procfs
   b. stan i konfiguracja systemu → sysfs
   c. pliki urządzeń → devfs
3. Manipulacja zasobami:
   a. składanie systemów plików → unionfs
   b. podłączanie systemów plików użytkownika → FUSE

Czym zarządzają systemy plików?

Pamięcią, z reguły zewnętrzną! Jednostką adresacji jest **sektor** (z reguły 512 bajtów). Dawniej adresowanie fizyczne używające **geometrii dysku** (CHS). Dziś **liniowe adresowanie** (LBA) → adresy logiczne tłumaczone na fizyczne przez **kontroler dysku**.

System uniksowy dostarcza abstrakcji nad pamięcią zewnętrzną w postaci **urządzeń blokowych**, tj. plików o swobodnym dostępie.

Sterowniki takich urządzeń używają bardzo skomplikowanych protokołów komunikacji ATAPI, SCSI, NVMe, USB, itd.

Urządzenia umożliwiają przeprowadzanie diagnostyki: `smartctl(8)` → czy z dyskiem wszystko ok?

Urządzenia blokowe

```
# sudo lsblk
NAME        MAJ:MIN RM   SIZE RO TYPE MOUNTPOINT
loop0         7:0    0  97,8M  1 loop /snap/core/10185
sda           8:0    0 223,6G  0 disk
├─sda1        8:1    0   512M  0 part /boot/efi
├─sda2        8:2    0 207,4G  0 part /
└─sda3        8:3    0  15,7G  0 part [SWAP]
sr0          11:0    1  1024M  0 rom
nvme0n1     259:0    0   477G  0 disk
├─nvme0n1p1 259:1    0   200M  0 part
└─nvme0n1p2 259:2    0 476,8G  0 part
```

loop → urządzenie blokowe, którego zawartość jest odwzorowana w plik zwykły, **part** → partycja, **sr** → pamięć stała

Mapa przestrzeni dyskowej

Gdzie umieścić **program rozruchowy** (ang. *boot loader*), systemy plików (`root`, `home`, ...), **przestrzeń wymiany**?

Dysk jest podzielony na **woluminy** zwane **partycjami**.

Tablica partycji (np. GPT) to dyskowa struktura danych przechowująca opis partycji.

Na dysku dwie kopie tablicy partycji, dla każdego wpisu sumy kontrolne.

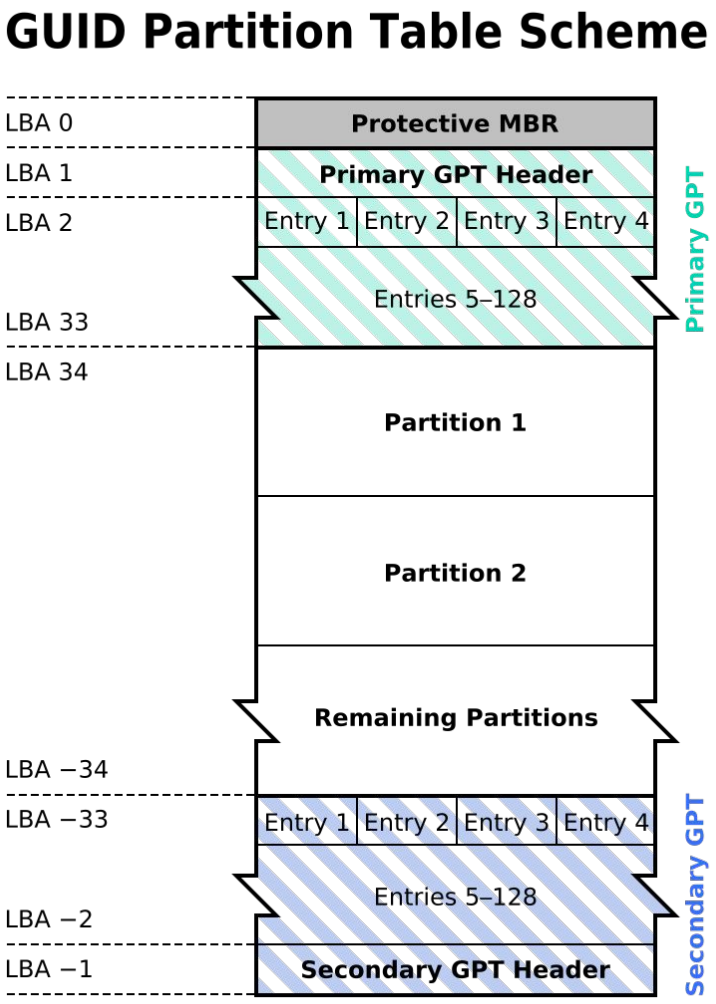

Partycje na moim służbowym dysku

```
# sudo fdisk -l -o Device,Start,End,Size,Type /dev/sda

Disk /dev/sda: 223.6 GiB, 240057409536 bytes, 468862128 sectors
Disk model: PNY CS1311 240GB
Units: sectors of 1 * 512 = 512 bytes
Sector size (logical/physical): 512 bytes / 512 bytes
I/O size (minimum/optimal): 512 bytes / 512 bytes
Disklabel type: gpt
Disk identifier: A66B1B27-99E1-408B-9840-573AA63E2939

Device         Start       End   Size Type
/dev/sda1       2048   1050623   512M EFI System
/dev/sda2    1050624 435965951 207.4G Linux filesystem
/dev/sda3  435965952 468860927  15.7G Linux swap
```

VFS: motywacja

Systemy plików mogą bardzo różnić się od siebie implementacją, np. dyskowymi strukturami danych, formatem metadanych. Każdy z systemów plików chcemy wkomponować w drzewiastą strukturę. Implementacja wywołań `open(2)`, `read(2)`, `write(2)`, ... dla każdego z systemów plików? Czy da się uwspólnić ten kod?

VFS to infrastruktura jądra do implementacji systemów plików. Na przykład w systemie NetBSD określono interfejsy:

- udostępniane przez sterownik systemu plików, a wymagane przez wywołania systemowe → `vnodeops(9)`, `vfsops(9)`
- wykorzystywane przez systemy plików:
  - buforowanie bloków dyskowych → `buffercache(9)`
  - kolejkowanie operacji dyskowych → `bufq(9)`
  - pamięć podręczna rozwiązywania ścieżek → `namecache(9)`

VFS: struktury danych jądra

Struktury danych każdego systemu plików są tłumaczone do:

`vnode` uniwersalna reprezentacja i-węzła w pamięci jądra

- typ pliku (`VDIR`, `VREG`, `VLNK`, ...)
- wczytany element struktury dyskowej (np. `i-node`)
- wskaźnik na tablicę operacji (a'la metody wirtualne) `vnodeops`

`vattr` uniwersalna reprezentacja metadanych pliku

- używane głównie przez `stat(2)` i `access(2)`

`mount` reprezentuje zamontowany system plików

- superblok, grupy bloków i inne prywatne dane systemu plików
- wskaźnik na tablicę operacji `vfsops`
- lista v-węzłów należących do instancji tego systemu plików

Fragmentacja systemu plików (1)

Systemy plików nie muszą przechowywać plików w ciągłym obszarze sektorów.
Fragmentacja zewnętrzna to nie problem!

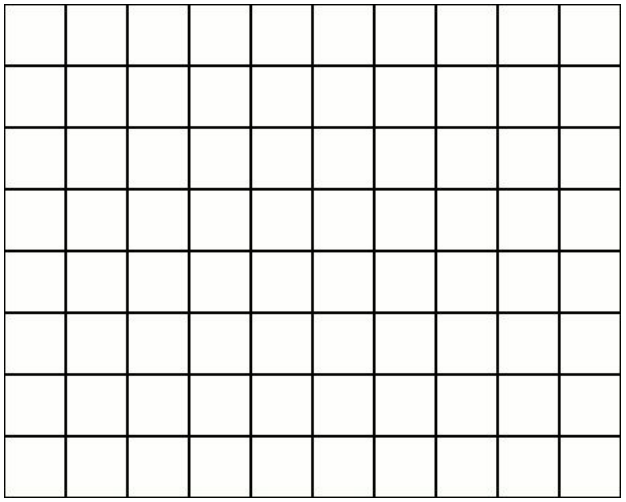

Plik jest pofragmentowany, jeśli jest przechowywany na dysku w więcej niż jednym spójnym fragmencie.

Zmiana pozycji głowicy dysku magnetycznego jest kosztowna.
Losowe dostępy do dysku SSD są również wolniejsze niż sekwencyjne.

Przydział ciągły jest korzystny zawsze!

Fragmentacja systemu plików (2)

Jak radzić sobie z **fragmentacją systemu plików**?

- pozostawienie miejsca za ostatnim blokiem zapobiega powstawaniu fragmentów przy dopisywaniu na koniec pliku
- **odroczony przydział bloków** (ang. *delayed allocation*) na k sekund, grupujemy w pamięci zapisy wymagające przydziału nowych bloków w nadziei na zmniejszenie ogólnej liczby fragmentów
- **usługa defragmentacji** narzędzie użytkownika lub wątek jądra

Jak radzić sobie z **fragmentację wewnętrzną** plików?

- **upakowywanie ogonów** (ang. *tail packing*) końcówki kilku plików pakujemy do jednego bloku, dobre jeśli pliki już nie rosną
- umieszczanie zawartości bardzo krótkich plików w miejscu wskaźników i-węzła (np. dowiązania symboliczne)

Organizacja prostego systemu plików (ext2)

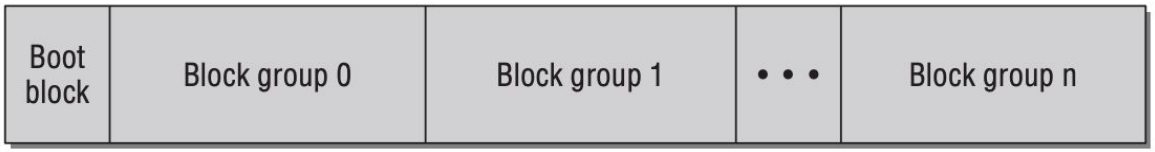

Boot → miejsce na program rozruchowy. Reszta miejsca podzielona na **grupy bloków** (**BG**) równego rozmiaru (prócz ostatniego).

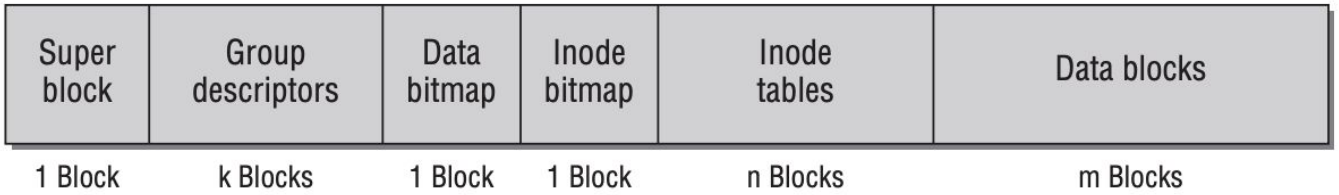

Superblok (**SB**) przechowuje najważniejsze właściwości systemu plików (`blksz`, `#blk`, `#inode`). **Deskryptory grup** (**GDs**) przechowują położenie i rozmiar **bitmapy zajętości** bloków i i-węzłów każdej grupy bloków.

`SB` i `GDs` są przechowywane w BG_0, a ich kopie w wyróżnionych BG_i.
System dąży do przydziału pliku w obrębie jednej `BG`.
Z góry przydzielona liczba i-węzłów → możliwych plików!

i-węzeł (ang. *i-node*)

Opis zasobu dyskowego.
Oprócz atrybutów zawiera wskaźniki na bloki danych i **bloki pośrednie** (ang. *indirect blocks*).

Przydział bloków w strukturze drzewiastej, która rośnie wraz z rozmiarem pliku.

i-węzeł ma 128B lub 256B

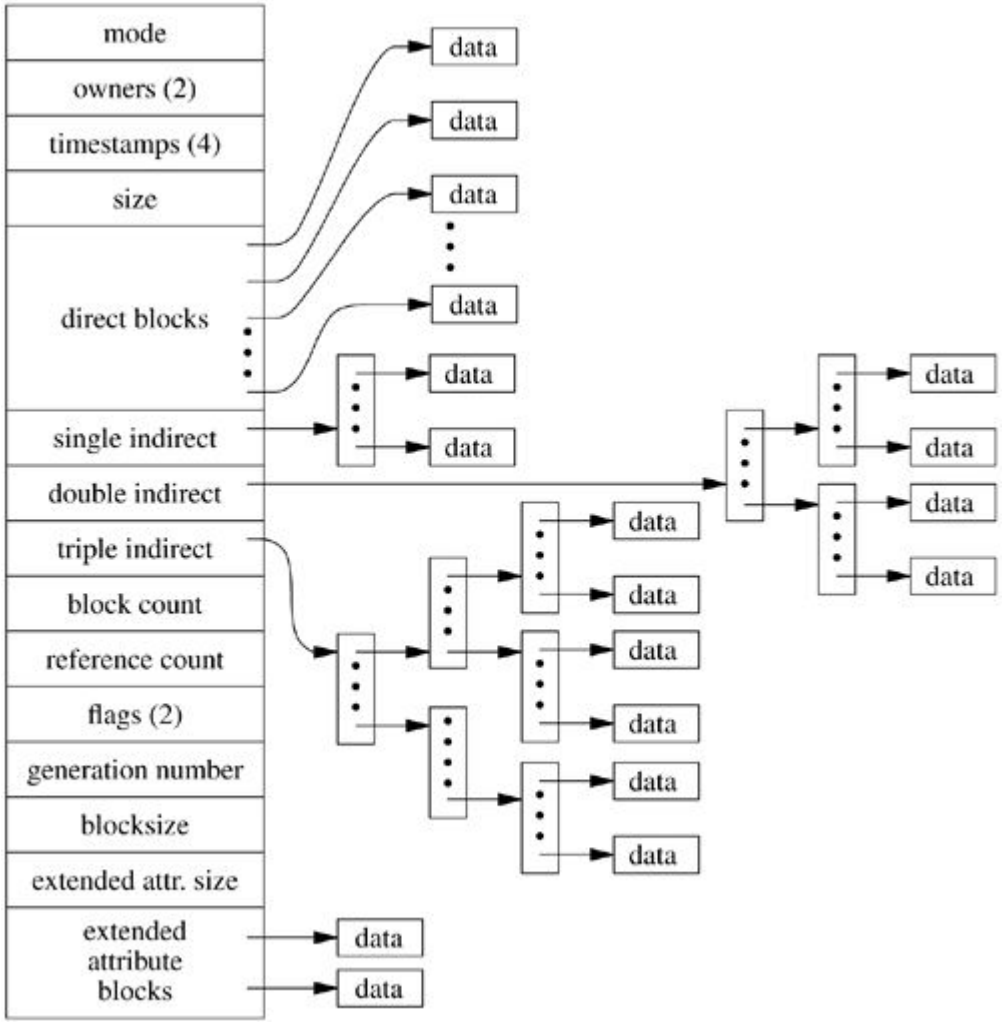

Reprezentacja katalogów

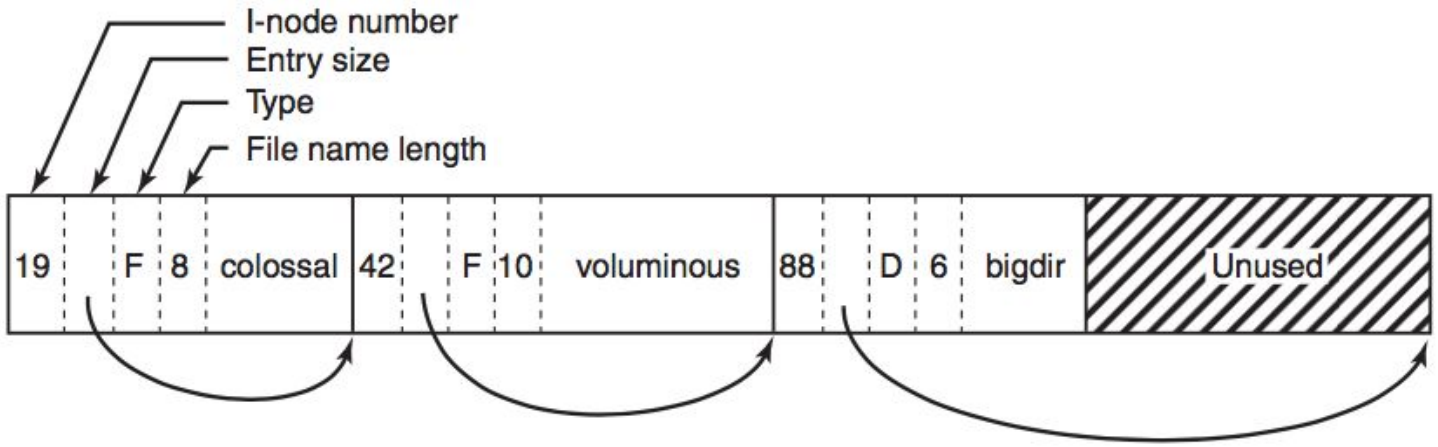

Reprezentacja listowa → liniowe wyszukiwanie, koszt niwelowany przez `namecache(9)`. Co jakiś czas potrzebne kompaktowanie! Dodawanie lub usuwanie plików potencjalnie wymaga przejrzenia całego katalogu.

Lepsze rozwiązania? HTree lub B+Tree.

> **[LKML] Add ext3 indexed directory (htree) support**
>
> Creating 100,000 files in a single directory took 38 minutes without directory indexing…
> and 11 seconds with the directory indexing turned on.

e2fsprogs: narzędzia systemu plików `ext[234]`

```
# truncate -s 100M disk.img
# /sbin/mkfs.ext4 -L testfs disk.img
# /sbin/dumpe2fs disk.img
# ls -lhs disk.img
```

`fsck` naprawianie uszkodzonego systemu plików

`resize2fs` zmiana rozmiaru systemu plików po zwiększeniu woluminu lub przed zmniejszeniem wolumenu

`tune2fs` zmiana parametrów systemu plików

`debugfs` przeglądanie struktur i właściwości systemu plików

NetBSD: sterownik `ext2fs`

Na potrzeby projektu programistycznego *“System plików”* *pożyczymy* definicje dyskowych struktury danych `ext2` z `NetBSD` (licencja `BSD` na to pozwala):

- superblok: `ext2fs`
- grupa bloków: `ext2_gd`
- i-węzeł: `ext2fs_dinode`
- wpis katalogu: `ext2fs_direct`

W trakcie programowania własnego sterownika za pomocą interfejsu FUSE możecie zaglądać do ich implementacji!

FUSE: Filesystem in Userspace

Co gdyby przetłumaczyć wywołania **vnodeops** i **vfsops** na datagramy i wysyłać do procesu w przestrzeni użytkownika?

Taki program korzysta z biblioteki `libfuse` i komunikuje się z jądrem przez `/dev/fuse`.

Można zaimplementować dowolny system plików nie modyfikując jądra systemu operacyjnego!

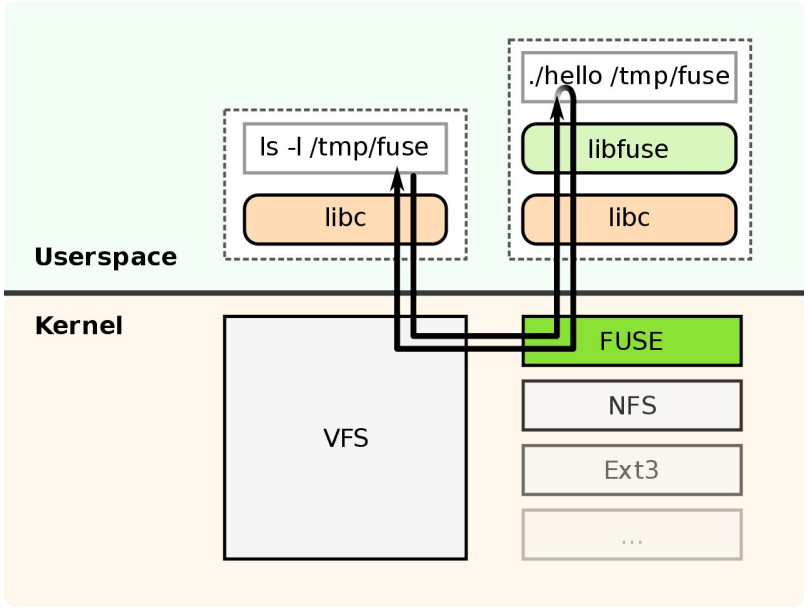

FUSE: lista operacji (przykład hello_ll.c)

fuse_lowlevel_ops imituje interfejs **vnodeops** i **vfsops**.

```
static const struct fuse_lowlevel_ops hello_ll_oper = {
   .lookup    = hello_ll_lookup,
   .getattr   = hello_ll_getattr,
   .readdir   = hello_ll_readdir,
   .open      = hello_ll_open,
   .read      = hello_ll_read,
   .readlink  = hello_ll_readlink,
};
```

Po obsłużeniu operacji odpowiadamy jądru przy użyciu funkcji **fuse_reply_*** z fuse_lowlevel.h. Jeśli wystąpił błąd to wysyłamy fuse_reply_err podając błąd z errno(2), np.:

ENOENT, **ENOTDIR**, **EISDIR**, **EACCESS**, ...

FUSE: operacje (1)

```
void (*lookup)(fuse_req_t req, fuse_ino_t parent,
               const char *name);
```

Sprawdź czy i-węzeł **parent** jest katalogiem, wyszukaj w nim wpis **name**, a następnie wypełnij w `fuse_entry_param` numer i-węzła i wyślij odpowiedź przy pomocy `fuse_reply_entry`.

```
void (*open)(fuse_req_t req, fuse_ino_t ino,
             struct fuse_file_info *fi);
```

Sprawdź czy plik identyfikowany przez i-węzeł **ino** można otworzyć z flagami zawartymi w **fi->flags** (np. **O_RDONLY**, **O_WRONLY**), jeśli tak to odpowiedz przy pomocy `fuse_reply_open`. Tożsamość już została sprawdzona przez jądro!

FUSE: operacje (2)

```
void (*getattr)(fuse_req_t req, fuse_ino_t ino,
                struct fuse_file_info *fi);
```

Dla i-węzła **ino** wypełnij strukturę stat i odeślij fuse_reply_attr.

```
void (*readdir)(fuse_req_t req, fuse_ino_t ino,
                size_t size, off_t off,
                struct fuse_file_info *fi);
```

Dla i-węzła **ino** wypełnij bufor o rozmiarze **size** wpisami katalogu posługując się fuse_add_direntry. Zacznij czytać katalog od miejsca wyznaczonego przez **off**, które zostało zwrócone z poprzedniej instancji wywołania **readdir**. Należy również podać wpisy ‘.’ i ‘..’. Uzupełniony bufor należy odesłać fuse_reply_buf.

FUSE: operacje (3)

```
void (*read)(fuse_req_t req, fuse_ino_t ino,
             size_t size, off_t off,
             struct fuse_file_info *fi);
```

Wczytaj z pliku o i-węźle **`ino`** maksymalnie **`size`** bajtów poczynając od pozycji **`off`**. To co się udało wczytać odeślij przy użyciu `fuse_reply_buf`.

```
void (*readlink)(fuse_req_t req, fuse_ino_t ino);
```

Sprawdź czy plik o i-węźle **`ino`** jest dowiązaniem symbolicznym, wczytaj jego zawartość w postaci ciągu znaków i odeślij przy użyciu `fuse_reply_readlink`.

Spójność systemu plików

Operacje na systemie plików nie są atomowe, np. zakładanie pliku:

- znajdź wolny i-węzeł i oznacz go jako zajęty (w bitmapie)
- zainicjalizuj i-węzeł
- wprowadź nowy wpis do katalogu (potencjalnie trzeba go powiększyć)

Jeśli w trakcie zapisu na dysk przydarzy się awaria systemu lub przerwa w dostawie energii, to system plików może zostać w **niespójnym** stanie. Po awarii musimy być w stanie odtworzyć jakiś spójny stan. Przydałoby się również zminimalizować ilość utraconych danych.

Chcemy zachować **spójność metadanych**, czyli danych nadających strukturę systemowi plików (katalogi, i-węzły, mapa wolnych bloków, itd.). Większość programów zakłada, że po wykonaniu operacji **`write`** dane są bezpieczne na dysku, ale to wymagałoby zachowania **spójności danych**.

Metody zachowania spójności

zapisy synchroniczne wymuszamy czekanie na zakończenie operacji wejścia-wyjścia. Niestety mogą powstawać wycieki pamięci dyskowej! Szybkość operacji ograniczona przepustowością dysku.

wsparcie sprzętowe pamięć NVRAM kontrolera dysku przechowuje niedokończone operacje. Szybkość operacji ograniczona pojemnością.

księgowanie (ang. *journalling*) zmiany metadanych zapisujemy jak **transakcje** do pliku dziennika zanim zostaną wprowadzone do systemu plików. Po awarii czytamy dziennik i odtwarzamy operacje.

copy-on-write trwała struktura systemu plików; poprzednia wersje obiektu nie ulegają zmianom, wskaźniki na bloki zawierają skrót bloku (ang. *hash*), tworzymy nowe wersje obiektu, a stare wersje z czasem zwalniamy; superblok trzyma ostatni spójny stan systemy plików

Kilka reguł zachowania spójności

- nie wolno zapisać wskaźnika na niezainicjowaną strukturę
  (i-węzeł musi być zainicjowany zanim ustalimy odpowiadający wpis katalogu)
- nie wolno ponownie użyć zasobu na który jeszcze ktoś wskazuje
  (należy wyzerować wskaźnik w mapie bloków i-węzła, zanim ponownie użyjemy tego bloku)
- nie usuwaj starego wskaźnika póki nie ustaliłeś nowego
  (zmieniając nazwę pliku – najpierw należy dodać nową nazwę, a potem usunąć starą)

Następujące akcje wymagają odpowiedniego uszeregowania operacji dyskowych, aby umożliwić sensowne wyjście z awarii systemu:

- utworzenie lub usunięcie pliku
- utworzenie lub usunięcie katalogu
- zmiana nazwy katalogu lub pliku
- przydział lub zwolnienie bloku
- operacja na bloku pośrednim (i-węzeł)

Księgowanie (ang. *journalling*)

Dziennik to miejsce na dysku przechowujące bufor cykliczny **transakcji** składających się z **operacji idempotentnych**. Wielokrotne wykonanie tej samej operacji idempotentnej nie zmienia wyniku: **zwiększ liczbę dowiązań twardych o 1** vs. **oznacz blok `k` jako używany**.

W trakcie działania system najpierw sekwencyjne zapisuje modyfikacje (z reguły tylko metadanych) do dziennika. Gdy tylko upewni się, że operacje zaksięgowano, wdraża je w życie, po czym unieważnia odpowiednie wpisy dziennika. Po awarii `fsck` musi zlokalizować czoło i ogon kolejki transakcji, odtworzyć je i sprawdzić spójność metadanych.

Przykładowe operacje wymagające księgowania: zmiana licznika referencji i-węzła, przydział lub zwolnienie bloku, zmiana położenia wpisu katalogu (kompaktowanie).

Journalling Block Device (na podstawie ext3)

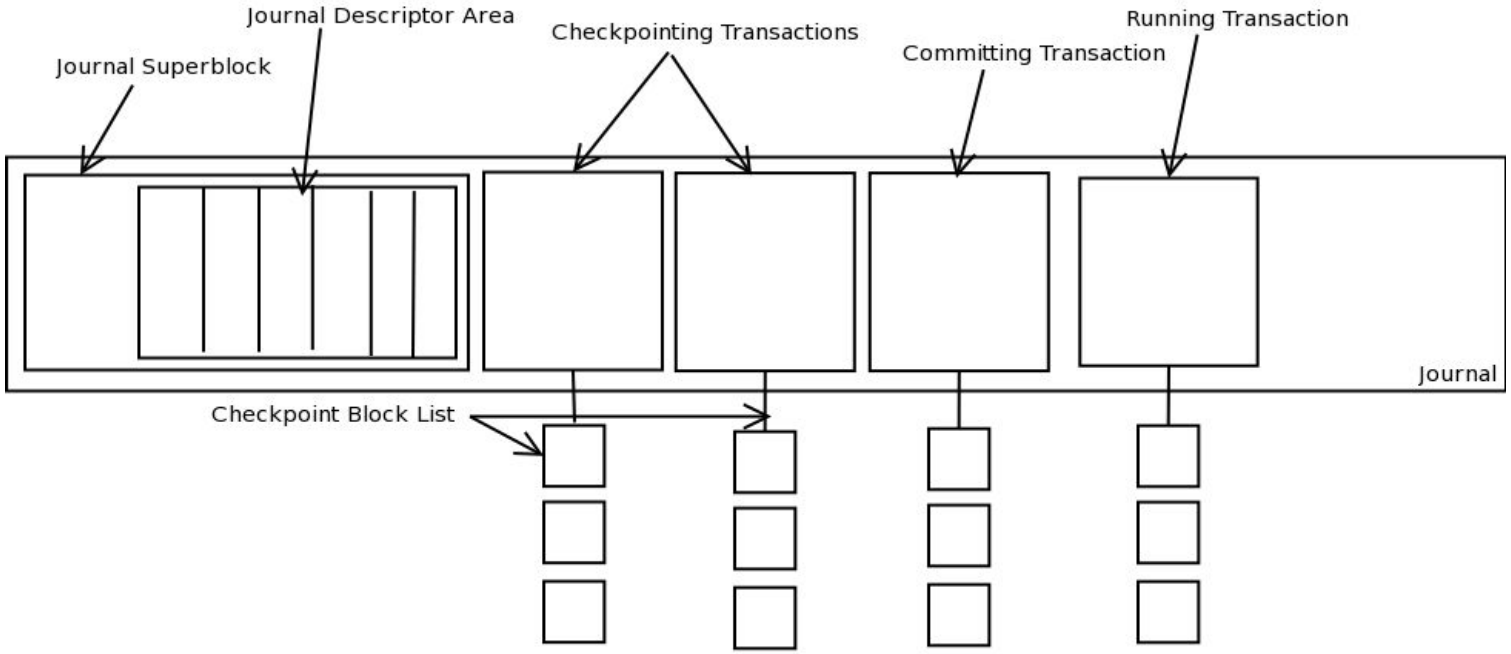

Journal: Logical View

JBD jest niezależny od systemu plików. Jedyną idempotentną operacją jest zapis bloku. Każda transakcja składa się z wielu zmodyfikowanych bloków. Blok k może występować w transakcji dokładnie raz.

Journalling Block Device (c.d.)

1. **Wystartuj nową transakcję (stan: in progress)**
   zaktualizuj dane jednego lub więcej bloków w obrębie transakcji
2. **Zakończ transakcję (stan: completed)**
   transakcja przechowywana w RAM, nie można już modyfikować
3. **Wypisanie transakcji (stan: commited)**
   jedną lub więcej transakcji wpisujemy do dziennika i oznaczamy jako kompletną; transakcje mogą być odtworzone z dziennika po awarii
4. **Przechodzenie punktów kontrolnych (stan: checkpointed)**
   modyfikacje są wpisywane do systemu plików, po czym transakcje są usuwane z dziennika; metadane powinny zostać zapisane na dysk przed zapisem danych

W **`ext3`** dziennik to specjalny plik (i-węzeł 8). Domyślnie księgowane są tylko modyfikacje metadanych, ale można również księgować dane.

Pytania?